

MAMADOU SAIDOU BALDE

AI Engineer | Data Scientist

PROFIL

AI Engineer | Data Scientiste avec plus de 5 ans d'expérience en conception et déploiement de solutions AI en production. Spécialisé en NLP, LLMs, RAG, Agent, MCP et MLOps, j'interviens de bout en bout : de l'exploration des données au déploiement via des environnements CI/CD. Expérience en environnements industriels exigeants (Nokia 5G), avec une approche orientée performance, robustesse et valeur métier.

COORDONNÉES

🏠 Paris, Île-de-France, France

☎ +33753266807

✉ baldeba772@gmail.com

🌐 [LinkedIn](#)

[GitHub](#)

[Hugging Face](#)

COMPÉTENCES

- **Python**, C, **SQL**, PySpark, Scala, R, SAS
- **Scikit-learn**, TensorFlow, **PyTorch**,
- **Transformers (BERT, GPT, Mistral)**,
- **RAG** (Retrieval-Augmented Generation)
- **LangChain** / orchestration LLM
- **NLP**, **LLM**, Computer Vision, Classification
- **Embedding & Vector Store**
- **Generative AI**, **Fine-tuning**, Prompt Engineering
- **Power BI**, Tableau, Looker Studio, Excel/VBA
- PostgreSQL, MySQL, MongoDB, Neo4j, Microsoft **SQL Server** (SSAS, SSIS, SSRS)
- Apache **Spark**, Hadoop, HDFS, **Databricks**
- **AWS** (SageMaker, EC2, S3, Lambda, ECS)
- Microsoft Azure (Azure ML, Data Factory)
- Google Cloud Platform (**GCP**) (**BigQuery**, **Vertex AI**, **Looker Studio**)
- **Docker**, **Kubernetes**, Jenkins, **Git/GitHub**, Gerrit, **CI/CD**, MLFlow
- **Agile** (Scrum), **Jira**, **Confluence**

LANGUES

- **Anglais** : Courant (Certification Cambridge)
- **Français** : Langue maternelle

CENTRES D'INTÉRÊT

- **Sports** : Musculation, Marathon, Football (Membre actif d'une équipe locale)
- **Loisirs** : Lecture (data science, IA, développement personnel), musique, manga

EXPÉRIENCE PROFESSIONNELLE

AI Engineer | Data Scientist, 09/2021 - 04/2025

Nokia Corporation – Massy Palaiseau

Membre au sein de la Squad CI_Metrics dans la division Mobile Network pour améliorer la stabilité et la performance des processus de la Continue Intégration pour le déploiement du réseau 5G L2/L3 dans un environnement Agile et international. :

- Extraction et traitement de très grands volumes de données complexes provenant de diverses sources pour surveiller et améliorer la stabilité des builds logiciels.
- Développement de métriques personnalisées pour évaluer les performances des systèmes (temps de compilation, taux de succès, stabilité des pipelines)
- Développement des modèles ML (régression, classification) pour prédire les échecs de builds, réduire les erreurs et anticiper les pannes.
- Conception de dashboards interactifs avec Power BI pour le suivi des indicateurs clés (temps de build, taux de succès).
- Mise en place de pipelines robustes pour automatiser l'extraction, la transformation, et la charge (ETL) des données en temps réel avec Python, SQL et Spark (PySpark, Scala).
- Chef de projet pour la conception et le déploiement d'un système automatisé de suivi de l'évolution des lignes de code (ajouts, suppressions, modifications).

Data Scientiste | Analyste, 02/2021 - 04/2021

Michelin – Clermont-Ferrand

Projet R&D visant à analyser les comportements de conduite à partir de données télématiques embarquées afin d'optimiser la reconnaissance des véhicules.

- Analyse d'un jeu de données de 2,7M d'observations (28 variables, 40 véhicules) issues de capteurs (accélérations 3 axes, vitesse, contexte météo, type de route, horaires).
- Feature engineering pour extraire des indicateurs comportementaux (agressivité, stabilité, variations longitudinales / latérales).
- Développement de modèles de ML pour optimiser la reconnaissance véhiculaire.
- Identification de patterns comportementaux liés à la météo et aux horaires de trajets

Data Scientist | Analyste, 04/2020 - 08/2020

Laboratoire Mathématiques de Blaise Pascal - Aubière, 63170, Étude statistique des déterminants socio-économiques des taux de criminalité en France à partir de données départementales.

- Analyse exploratoire et modélisation statistique sur 96 départements français (corrélations, clustering, analyse multivariée)
- Étude des taux de crimes contre les personnes, cambriolages et vols automobiles en lien avec des variables socio-économiques (chômage, pauvreté, urbanisation, familles monoparentales)
- Etude de corrélations significatives entre criminalité, précarité et densité urbaine.
- Production d'analyses et visualisations destinées aux chercheurs du laboratoire et aux autorités partenaires.

Projet NLP / LLM | RAG - Chatbot Médical IA

Développement d'un chatbot médical intelligent utilisant Retrieval-Augmented Generation (RAG) :

- Implémenté une architecture RAG avec LangChain pour interroger une base de connaissances médicales PDF
- Intégré le modèle avec embeddings sentence-transformers pour la compréhension contextuelle
- Utilisé FAISS pour l'indexation vectorielle et la recherche sémantique dans les documents médicaux
- Déployé sur HuggingFace Spaces pour un accès public : [Medical Chatbot Space](#)
- Technologies : Python, LangChain, Transformers, FAISS, Gradio, HuggingFace

FORMATION

Master Data Science & AI, Data ScienceTech Institute, Nice 09/2021 - 11/2023

Master Mathématiques Appliquées & Statistiques, Université Clermont Auvergne (09/2019 – 04/2021)

Licence Mathématique, Aix-Marseille-Université (09/2018 - 04/2019)